TD5 à TD7 : Tests d'hypothèse

Introduction

Les tests d'hypothèse sont très utilisés dans les sciences biologiques et humaines.

Revenons à l'exemple du poids des agneaux à la naissance. On veut tester statistiquement si le poids moyen est significativement différent de 4 kg.

étape 1 : On va supposer que la moyenne n'est pas significativement différente de 4 (hypothèse nulle $H_0 : \mu = 4$).

étape 2 : On prélève un échantillon de taille n et on calcule sa moyenne $\bar{X}_n$. On connait la distribution sous H_0 de $Z = \sqrt{n} \times \frac{\bar{X}_n - 4}{\hat{\sigma}}$, c'est une loi $\mathcal{N}(0, 1)$.

étape 3 : On calcule $p.value = \mathbb{P}(|Z| > z_{obs})$ où z_{obs} est la valeur de Z calculée sur l'échantillon observé.

étape 4 : On rejette l'hypothèse H_0 au risque α lorsque

$$p.value < \alpha$$

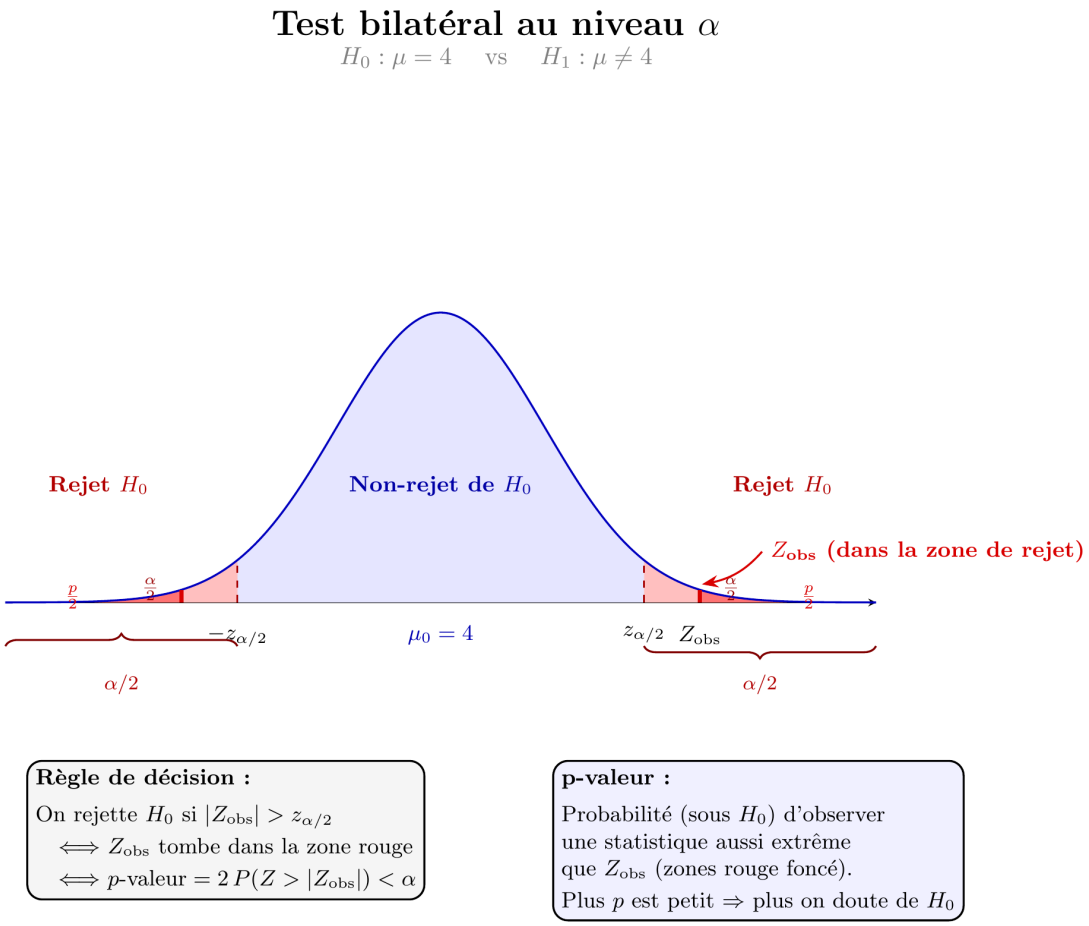


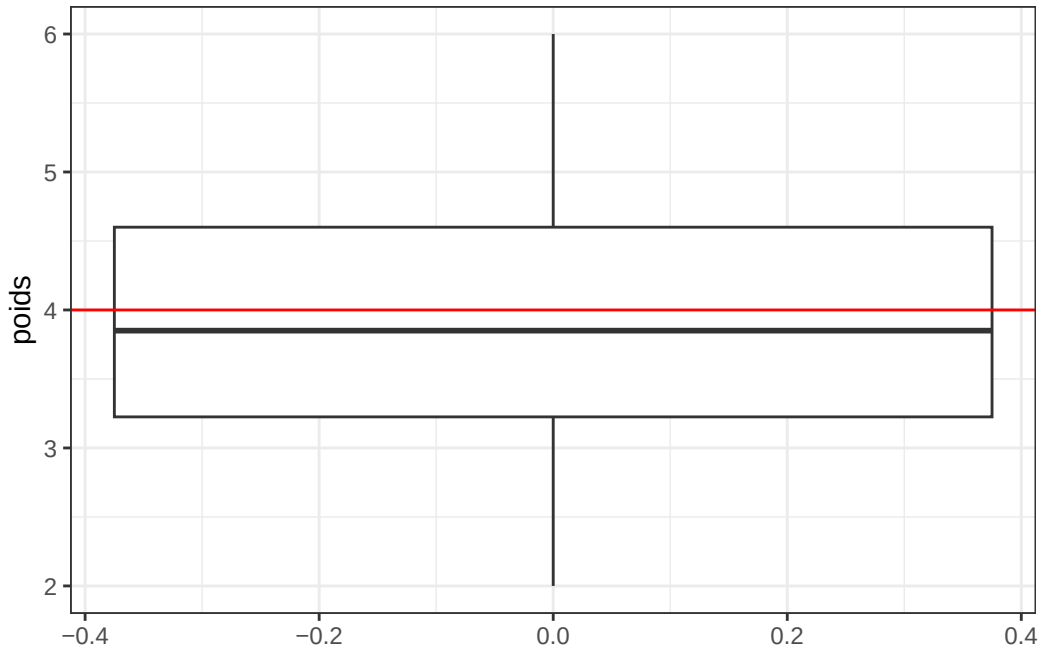
Figure 1: test d'hypothèse

Mise en oeuvre sur R

On reprend les données concernant les agneaux, on commence toujours par une analyse descriptive des données :

```
load("data/Agneaux.RData")
data<-unlist(Agneaux$PN)
library(ggplot2)
ggplot(data.frame(poids=data),aes(y=poids))+
  geom_boxplot()+
```

```
  geom_hline(yintercept = 4,color="red")+
  theme_bw()
```




```
# Moyenne des poids
mean(data)
```

```
[1] 3.890909
```

```
# Ecart type estimé des poids
sd(data)
```

```
[1] 1.00701
```

La mise en oeuvre du test se fait via la fonction t.test().

```
t.test(data,mu = 4)
```

```

    One Sample t-test
```

```
data:  data
t = -0.88009, df = 65, p-value = 0.3821
alternative hypothesis: true mean is not equal to 4
95 percent confidence interval:
 3.643355 4.138463
sample estimates:
mean of x
 3.890909
```

Lecture du résultat :

- La valeur de t correspond à la valeur de la statistique calculée sur les données observées. Remarque $t = 0$ correspond à la moyenne de l'écahntillon est égale à la valeur testée (ici $\mu = 4$).
- Le df (degree of freedom) est le degré de liberté. C'est le nombre d'informations indépendantes disponible pour estimer la statistique $T = \frac{\bar{X}_n - \mu}{\hat{\sigma}}$. Ici c'est $n-1$ car pour calculer $\hat{\sigma}$ on a $n-1$ valeurs indépendantes (la moyenne est calculée à partir des n valeurs observées).
- La p-value est $\mathbb{P}_{\mathcal{H}_0}(|T| > t)$. Elle vaut ici p-value= 0.3820535

Conclusion du test

- Conclusion statistique du test : Au risque de \$5\%\$, on ne peut pas rejeter l'hypothèse $\mathcal{H}_0$ (\$t(64)=-0.80,p=0.428\$).
- Conclusion : Le poids moyen à la naissance de la population d'agneau n'est pas significativement différente de 4 kg.

Test de comparaison de deux moyennes

Il s'agit du test de Student. Il repose sur des hypothèses concernant la forme de la distributions des données :

Test de Student

On considère une caractéristique X dont la distribution est connue sur deux poulations A, B :

$$X_A \sim \mathcal{N}(\mu_A, \sigma_A), \quad X_B \sim \mathcal{N}(\mu_B, \sigma_B).$$

On veut tester l'hypothèse il n'existe pas de différence significative entre les deux moyennes c'est à dire :

$$\mathcal{H}_0 : \mu_A = \mu_B, \quad versus \quad \mathcal{H}_1 : \mu_A \neq \mu_B.$$

On a deux cas :

- (Student classique) les variance σ_A^2, σ_B^2 sont inconnues mais supposées égales. On estime la variance commune $s_p^2 = \frac{n_A s_A^2 + n_B s_B^2}{n_A + n_B - 2}$ et on a

$$T = \frac{\bar{X}_A - \bar{X}_B}{s_P \sqrt{\frac{1}{n_A} + \frac{1}{n_B}}} \sim t_{n_A + n_B - 2}.$$

- (Welch) les variance σ_A^2, σ_B^2 sont inconnues et inégales. On estime chaque variance et on a

$$T = \frac{\bar{X}_A - \bar{X}_B}{\sqrt{\frac{s_A^2}{n_A} + \frac{s_B^2}{n_B}}} \sim t_\nu.$$

  où ν est le degré de liberté calculé en fonction de n_A, n_B.

Dans les deux cas on a $p.value = \mathbb{P}_{\mathcal{H}_0}(|T| > t_{obs})$

Reprenons le fichier Agneaux :

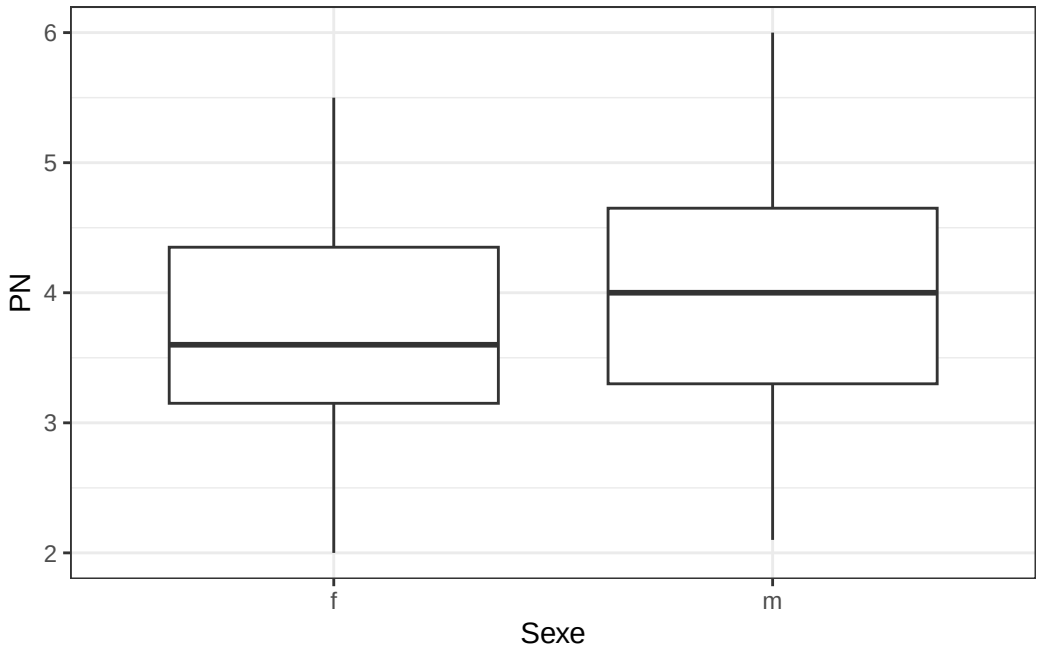
Exemple

On veut savoir si il existe une différence statistique entre les poids moyens des agneaux selon le sexe. On va tester l'hypothèse $H_0 : \mu_F = \mu_M$.

Comme précédemment on commence par une analyse descriptive des données :

- sous forme de graphiques :

```
ggplot(Agneaux,aes(x=Sexe,y=PN))+
  geom_boxplot()+
  theme_bw()
```



-sous forme de tableau :

```
library(dplyr)
```

```
Attachement du package : 'dplyr'

Les objets suivants sont masqués depuis 'package:stats':

    filter, lag

Les objets suivants sont masqués depuis 'package:base':

    intersect, setdiff, setequal, union
```

```
library(gt)
Agneaux |>
  group_by(Sexe) |>
  summarise(M=mean(PN),SD=sd(PN))|>
  gt() |>
  fmt_number(
    decimals = 2
  )
```

Sexe	M	SD
f	3.75	0.96
m	4.05	1.05

On peut alors faire les deux versions du test de Student

```
t.test(PN~Sexe, data=Agneaux,var.equal=T)
```

```
    Two Sample t-test

data:  PN by Sexe
t = -1.1746, df = 64, p-value = 0.2445
alternative hypothesis: true difference in means between group f and group m is not equal to
95 percent confidence interval:
 -0.7855999  0.2038487
sample estimates:
mean in group f mean in group m
       3.754286        4.045161
```

```
t.test(PN~Sexe, data=Agneaux)
```

```
    Welch Two Sample t-test

data:  PN by Sexe
t = -1.1679, df = 61.167, p-value = 0.2474
alternative hypothesis: true difference in means between group f and group m is not equal to
95 percent confidence interval:
 -0.7888706  0.2071194
sample estimates:
mean in group f mean in group m
       3.754286        4.045161
```

Les résultats sont proches (car ….).

On en déduit qu'au risque de 5% on ne peut pas rejeter l'hypothèse H_0. Donc il n'existe pas de différence significative de poids moyen des agneaux selon le sexe.

Exercice

Télécharger et ouvrir le fichier Veaux. Ce fichier contient des caractéristiques physiques d'un veau (A,B,C) et de leur mère (BIM, HSP, LH, LB). On veut savoir si il existe un lien entre le fait que le veau soit né par césarienne et ses caractéristiques physiques ? de même avec les caractéristiques physiques de sa mère.

Tests de corrélation linéaire et droite de régression

On considère deux caractéristiques quantitatives X, Y définies sur une même population. On cherche à savoir si on peut prédire la valeur de Y en fonction de la valeur de X, autrement dit si il existe un lien entre X et Y.

Le modèle le plus simple pour répondre à cette question est le modèle linéaire c'est à dire

$$f(X) = \beta_0 + \beta_1 X,$$

où β_0 est l'ordonnée à l'origine (intercept) et β_1 la pente (slope) qui correspond à l'inclinaison de la droite. Utiliser un modèle linéaire suppose que le lien entre X et Y est monotone c'est à dire une des deux situations suivantes :

- Si X augmente alors Y augmente ($\beta_1 > 0$)
- Si X augmente alors Y diminue ($\beta_1 < 0$)

Evidemment le modèle ne sera pas parfait on aura $Y \simeq f(X)$, on va écrire

$$Y = f(X) + e,$$

où e sont les résidus du modèle.

On cherche la droite qui minimise le carré des résidus :

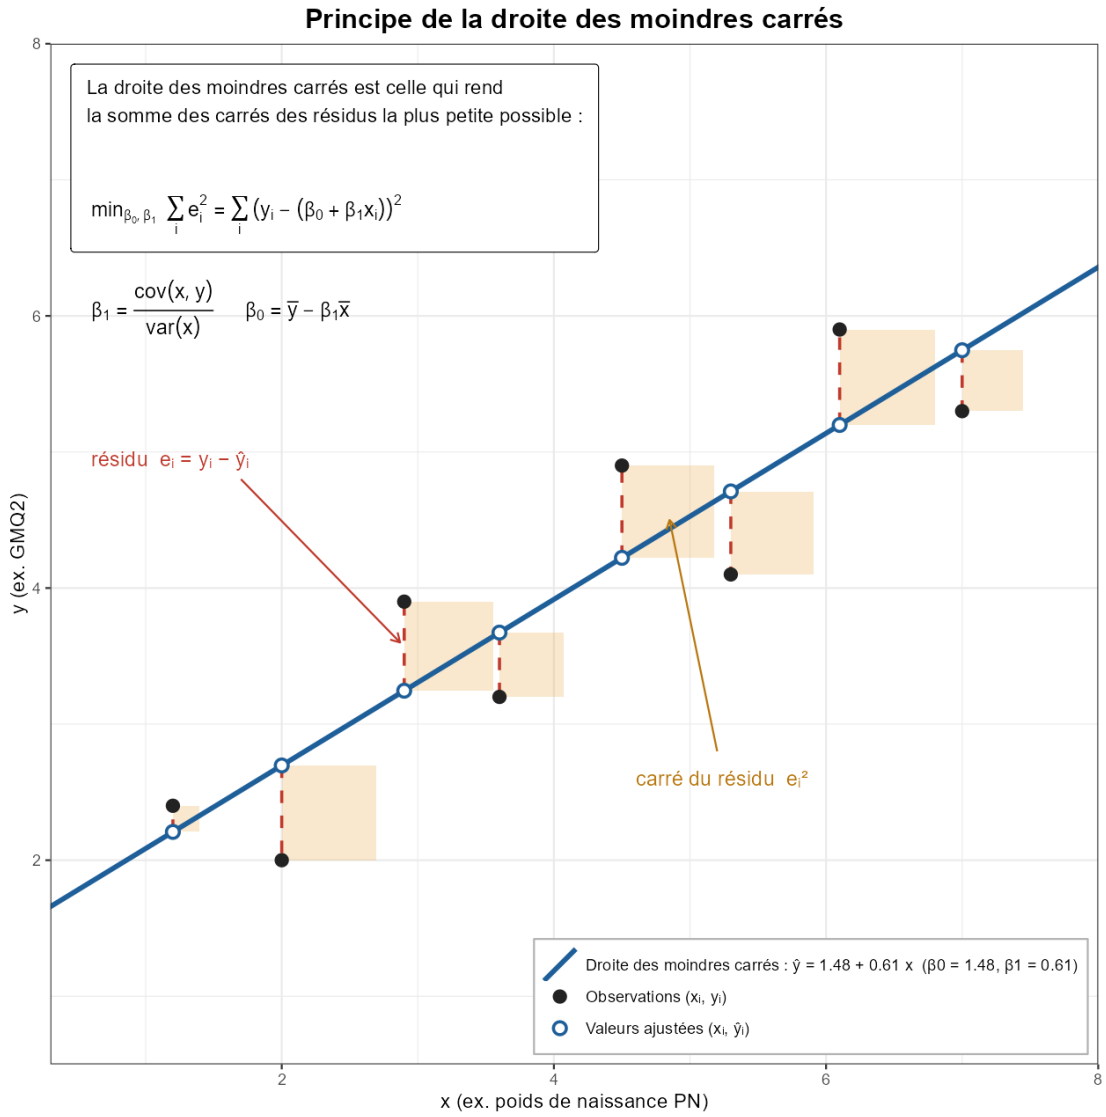


Figure 2: principe droite des moindres carrés

Variance, Covariance, coefficient de corélation

On va donner les versions empiriques de ces notions. Considérons un échantillon de n individus pour lesquels on connait les valeurs de X $(x_1, ...x_n)$ et de Y $(y_1, ..., y_n)$. On définit :

- Les variances empiriques de X et de Y : $\sigma_X^2 = \frac{1}{n}\sum_{i=1}^n (x_i - \bar{x})^2$ et $\sigma_Y^2 = \frac{1}{n}\sum_{i=1}^n (y_i - \bar{y})^2$

- La covariance empirique de X, Y : $\sigma_{X,Y} = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})$
- Le coeffcient de corrélation empirique de X, Y :

$$r_{X,Y} = \frac{\sigma_{X,Y}}{\sigma_X \sigma_Y}, \quad \text{coefficient Bravais-Pearson.}$$

Il y a un lien étroit entre le coefficient de corrélation linéaire et la pente β_1 de la droite de régression :

$$r = 0 \iff \beta_1 = 0.$$

On peut tester le lien entre les variables X, Y en utilisant l'un des tests suivant :

Test du lien linéaire entre deux variables quantitatives

- Test de Bravais Pearson : on teste $\mathcal{H}_0 : r = 0$ versus $\mathcal{H}_1 : r \neq 0$. On utilise la statistique

$$T = \frac{r\sqrt{n-2}}{\sqrt{1-r^2}} \sim t_{n-2},$$

et on rejette $\mathcal{H}_0$ au risque α si $p.value = P(|T| > t_{obs}) < \alpha$.
- Test de la pente : on teste $\mathcal{H}_0 : \beta_1 = 0$ versus $\mathcal{H}_0 : \beta_1 \neq 0$. On utilise la statistique

$$T = \frac{\beta_1}{se_{\beta_1}} \sim t_{n-2},$$

où $se_{\beta_1} = \sqrt{\frac{\sigma^2}{\sigma_X^2}}$ et $\sigma^2 = \frac{1}{n-2}\sum_{i=1}^{n} e_i^2$.

Deux tests sont exactement équivalents en régression linéaire avec une seule variable X.

Exemple

On veut tester si il existe un lien significatif entre les poids moyens des agneaux à la naissance et GMQ2 (Gain Moyen Quotidien) des agneaux. On va tester l'hypothèse $H_0 : r_{PN,GMQ2} = 0$.

```
mod <- lm(GMQ2 ~ PN, data = Agneaux)
summary(mod)
```

```
Call:
lm(formula = GMQ2 ~ PN, data = Agneaux)
```

```
Residuals:
     Min       1Q   Median       3Q      Max
-242.841  -28.710    7.491   40.213  115.387

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)   35.809     31.468   1.138    0.259
PN            52.935      7.833   6.758 4.95e-09 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 63.6 on 64 degrees of freedom
Multiple R-squared:  0.4164,    Adjusted R-squared:  0.4073
F-statistic: 45.66 on 1 and 64 DF,  p-value: 4.946e-09
```

```r
cor.test(Agneaux$PN,Agneaux$GMQ2)
```

```
    Pearson's product-moment correlation

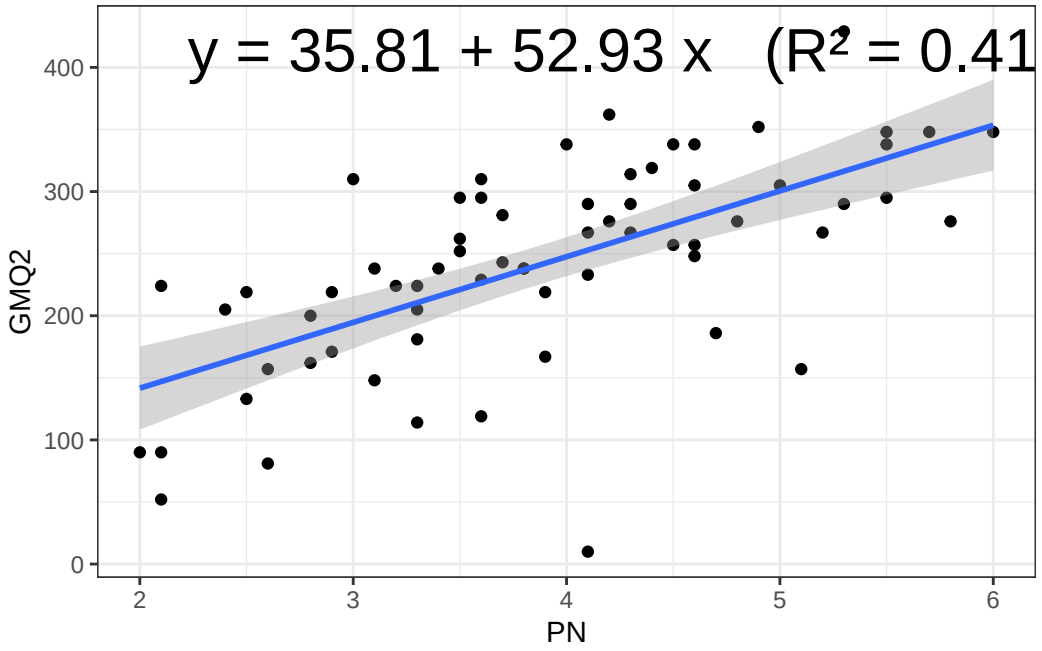
data:  Agneaux$PN and Agneaux$GMQ2
t = 6.7575, df = 64, p-value = 4.946e-09
alternative hypothesis: true correlation is not equal to 0
95 percent confidence interval:
 0.4778971 0.7674607
sample estimates:
      cor
0.6452911
```

```r
beta0  <- coef(mod)[1]
beta1  <- coef(mod)[2]
r2 <- summary(mod)$r.squared

eq <- paste0("y = ", round(beta0, 2), ifelse(beta1 >= 0, " + ", " - "),
             abs(round(beta1, 2)), " x   (R² = ", round(r2, 3), ")")

ggplot(Agneaux, aes(x = PN, y = GMQ2)) +
  geom_point() +
  geom_smooth(method = "lm") +
  annotate("text", x = -Inf, y = Inf, label = eq,
           hjust = -0.1, vjust = 1.5, size = 8) +
  theme_bw()
```

```
`geom_smooth()` using formula = 'y ~ x'
```



Exercice

On veut savoir si il existe un lien entre les caractéristiques physiques des veaux (A,B,C).

Tests du χ^2

Test d'homogénéité

Le test d'adéquation est similaire à un test sur une moyenne dans le sens où il ne concerne qu'une seule caractéristique qualitative. Il est souvent utilisé pour étudier la répartition des modalités de cette caractéristique qualitative et en particulier, une des questions usuellement posée est l'homogénéité de la répartition des individus dans les différentes modalités.

Test du χ^2 d'homogénéité

Soit X une caractéristique qualitative dont les modalités sont notées $1, \dots, I$. On considère un échantillon de taille n de valeurs de X.
Soit $\hat{p}_1, \dots, \hat{p}_I$ les proportions d'individus de l'échantillons appartenant aux différentes modalités $1, ..., I$.

Soit $(p_1^{(0)}, ..., p_I^{(0)})$ un vecteur de I proportions.
Hypothèses

$$\begin{cases} H_0 : p_i = p_i^{(0)} \\ H_1 : p_i \neq p_i^{(0)} \end{cases}$$

Statistique de test

$$\chi^2_{obs} = n \sum_{i=1}^{I} \frac{\left(p_i - p_i^{(0)}\right)^2}{p_i^{(0)}}$$

Sous H_0, cette statistique suit approximativement une loi du χ^2 à

$$\nu = (I - 1) \text{ degrés de liberté.}$$

Règle de décision (au risque α) On rejette H_0 si

$$p\text{-value} = P(\chi^2_\nu \geq \chi^2_{obs}) < \alpha$$

i Exercice

On veut savoir si pour les deux caractéristiques considérées la répartition est homogène.

On commence par une analyse descriptive univariée des données

```
table(Agneaux$Sexe)
```

```
 f  m
35 31
```

```
table(Agneaux$ClasseGMQ3)
```

```
  I  II III
 20  23  23
```

```
library(dplyr)
library(gtsummary)
Agneaux |>
  select(Sexe,ClasseGMQ3) |>
  tbl_summary()
```

Characteristic	**N = 66**[1]
Sexe	
f	35 (53%)
m	31 (47%)
ClasseGMQ3	
I	20 (30%)
II	23 (35%)
III	23 (35%)

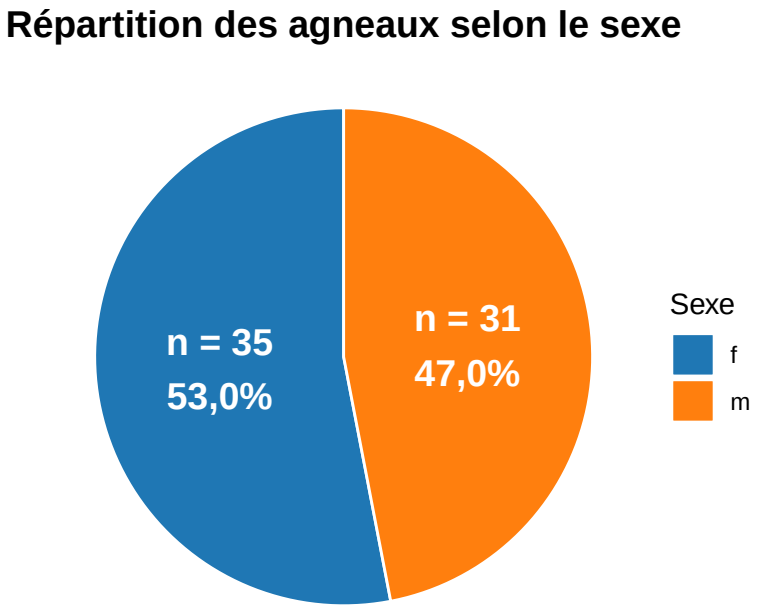
[1] n (%)

Le sexe est une caractéristique qualitative nominale (on ne peut pas classer les modalités), on utilise souvent un diagramme circulaire (camembert) pour représenter ces données :

```
library(ggplot2)
library(dplyr)
library(scales)

# Calcul des effectifs, des pourcentages et des étiquettes
tab <- Agneaux |>
  filter(!is.na(Sexe)) |>
  count(Sexe) |>
  mutate(
    pct   = n / sum(n),
    label = paste0("n = ", n, "\n",
                   percent(pct, accuracy = 0.1, decimal.mark = ","))
  )

# Diagramme circulaire
ggplot(tab, aes(x = "", y = n, fill = Sexe)) +
  geom_col(width = 1, color = "white") +
  coord_polar(theta = "y", start = 0) +
  geom_text(aes(label = label),
            position = position_stack(vjust = 0.5),
            size = 5, color = "white", fontface = "bold") +
  scale_fill_manual(values = c("#1f77b4", "#ff7f0e")) +
  labs(title = "Répartition des agneaux selon le sexe", fill = "Sexe") +
  theme_void() +
  theme(plot.title = element_text(hjust = 0.5, face = "bold", size = 14))
```



Dans le cas d'homogénéité on a $p_M^{(0)} = p_F^{(0)} = \frac{1}{2}$.

On fait le test sur R :

```
obs<-table(Agneaux$Sexe)
chisq.test(obs,p=c(1/2,1/2))
```

```
    Chi-squared test for given probabilities

data:  obs
X-squared = 0.24242, df = 1, p-value = 0.6225
```

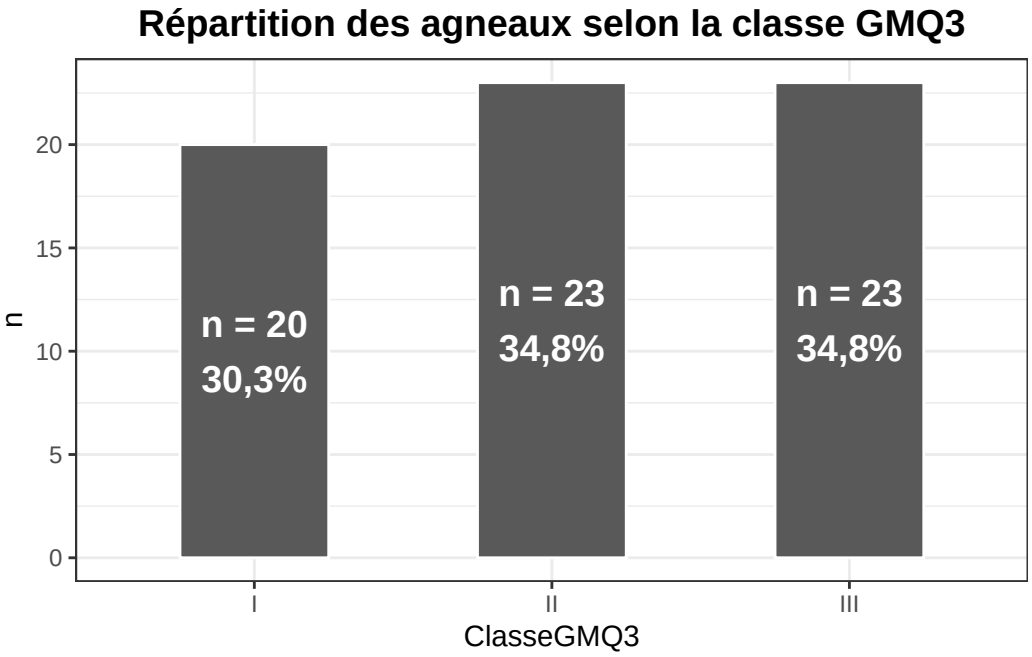
Pas de déviation significative de l'homogénéité ($\chi^2(1) = 0.24242, p - value = 0.6225$).

La variable ClasseGMQ3 est une caractéristique qualitative ordinale (les modalités peuvent être ordonnées) on utilisera plutôt un barplot :

```
# Calcul des effectifs, des pourcentages et des étiquettes
tab <- Agneaux |>
  filter(!is.na(ClasseGMQ3)) |>
  count(ClasseGMQ3) |>
  mutate(
```

```
    pct   = n / sum(n),
    label = paste0("n = ", n, "\n",
                   percent(pct, accuracy = 0.1, decimal.mark = ","))
  )

# Diagramme en bâtons
ggplot(tab, aes(x=ClasseGMQ3,y=n)) +
  geom_col(width = .5, color = "white") +
  #coord_polar(theta = "y", start = 0) +
   geom_text(aes(label = label),
             position = position_stack(vjust = 0.5),
             size = 5, color = "white", fontface = "bold") +
   scale_fill_manual(values = c("#1f77b4", "#ff7f0e")) +
   labs(title = "Répartition des agneaux selon la classe GMQ3") +
   theme_bw()+
   theme(plot.title = element_text(hjust = 0.5, face = "bold", size = 14))
```



Dans le cas d'homogénéité on a $p_1 = p_2 = p_3 = \frac{1}{3}$.

On fait le test sur R :

```
obs<-table(Agneaux$ClasseGMQ3)
chisq.test(obs,p=c(1/3,1/3,1/3))
```

	ClasseGMQ3			
	I	II	III	Total
Sexe				
f	11 (55%)	14 (61%)	10 (43%)	35 (53%)
m	9 (45%)	9 (39%)	13 (57%)	31 (47%)
Total	20 (100%)	23 (100%)	23 (100%)	66 (100%)

```
    Chi-squared test for given probabilities

data:  obs
X-squared = 0.27273, df = 2, p-value = 0.8725
```

Pas de déviation significative de l'homogénéité ($\chi^2(1) = 0.27273, p - value = 0.8725$).

Test d'indépendance :

On considère deux caractéristiques X, Y qualitatives. On veut tester l'existence d'un lien statistique entre ces deux caractéristiques.

```
table(Agneaux$Sexe,Agneaux$ClasseGMQ3)
```

```
   I II III
f 11 14  10
m  9  9  13
```

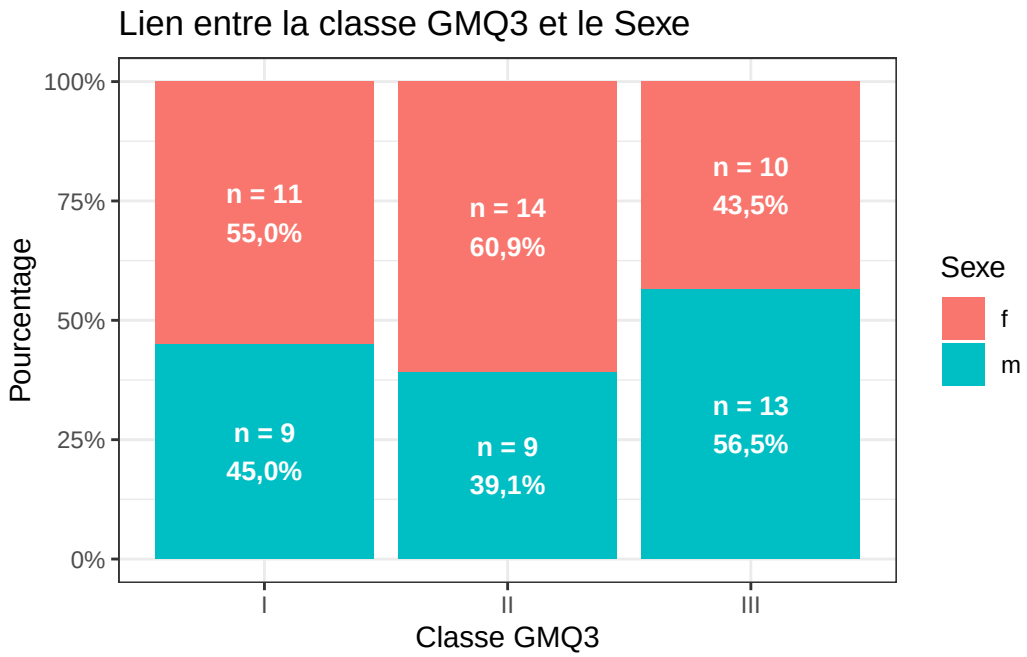
```
Agneaux |>
  select(Sexe, ClasseGMQ3) |>
  tbl_cross(
    row     = Sexe,
    col     = ClasseGMQ3,
    percent = "column"
  )
```

Maintenant on va représenter le lien entre les deux variables : sous forme de tableaux :

```r
library(ggplot2)
library(dplyr)
library(scales)

tab <- Agneaux %>%
  filter(!is.na(ClasseGMQ3), !is.na(Sexe)) %>%
  count(ClasseGMQ3, Sexe) %>%
  group_by(ClasseGMQ3) %>%
  mutate(
    pct   = n / sum(n),
    label = paste0("n = ", n, "\n",
                   percent(pct, accuracy = 0.1, decimal.mark = ","))
  ) %>%
  ungroup()

ggplot(tab, aes(x = ClasseGMQ3, y = n, fill = Sexe)) +
  geom_col(position = "fill") +
  geom_text(aes(label = label),
            position = position_fill(vjust = 0.5),
            size = 3.5, color = "white", fontface = "bold") +
  labs(title = "Lien entre la classe GMQ3 et le Sexe",
       x = "Classe GMQ3",
       y = "Pourcentage") +
  scale_y_continuous(labels = scales::percent) +
  theme_bw()
```



Pour tester le lien entre les deux caractéristiques on utilise :

Test du χ^2 d'indépendance

Soient X une variable à I modalités $x_1, \dots, x_I$ et Y une variable à J modalités $y_1, \dots, y_J$, observées sur un échantillon de taille n.

Hypothèses

$$\begin{cases} H_0 : X \text{ et } Y \text{ sont indépendantes} \\ H_1 : X \text{ et } Y \text{ ne sont pas indépendantes} \end{cases}$$

Notations

- n_{ij} : effectif observé du croisement (x_i, y_j)
- $n_{i\bullet} = \sum_{j=1}^{J} n_{ij}$: effectif marginal de la ligne i
- $n_{\bullet j} = \sum_{i=1}^{I} n_{ij}$: effectif marginal de la colonne j
- $n = \sum_{i=1}^{I} \sum_{j=1}^{J} n_{ij}$: effectif total

Effectifs théoriques sous H_0

$$E_{ij} = \frac{n_{i\bullet} \times n_{\bullet j}}{n}$$

Statistique de test

$$\chi^2_{obs} = \sum_{i=1}^{I}\sum_{j=1}^{J} \frac{(n_{ij} - E_{ij})^2}{E_{ij}}$$

Sous H_0, cette statistique suit approximativement une loi du χ^2 à

$$\nu = (I-1)(J-1) \text{ degrés de liberté.}$$

Règle de décision (au risque α) On rejette H_0 si

$$p\text{-value} = P(\chi^2_\nu \geq \chi^2_{obs}) < \alpha$$

Conditions d'application
Les effectifs théoriques doivent être suffisants : $E_{ij} \geq 5$ pour tout (i, j). Sinon, on regroupe des modalités ou on utilise le test exact de Fisher.

```
obs<-table(Agneaux$Sexe, Agneaux$ClasseGMQ3)
chisq.test(obs)
```

```
    Pearson's Chi-squared test

data:  obs
X-squared = 1.4411, df = 2, p-value = 0.4865
```

```
fisher.test(table(Agneaux$Sexe, Agneaux$ClasseGMQ3),simulate.p.value = TRUE, B = 10000)
```

```
    Fisher's Exact Test for Count Data with simulated p-value (based on
    10000 replicates)

data:  table(Agneaux$Sexe, Agneaux$ClasseGMQ3)
p-value = 0.5083
alternative hypothesis: two.sided
```

Exercice :

Un cheval hirsute a un pelage anormalement long, épais et souvent bouclé, qui ne tombe pas correctement au printemps (défaut de mue). Les données sont dans ce fichier Hirsutisme.

La caractéristique PUPD indique la présence ou l'absence de ce signe clinique chez chaque cheval ou poney :

- OUI : le propriétaire ou le vétérinaire a observé que l'animal boit et urine anormalement beaucoup ;
- NON : ce signe n'a pas été observé.

Répondre aux questions suivantes :

Partie 1 :

1. Peut-on penser que l'âge est différent selon le statut PUPD ?
2. Peut-on penser que plus la cortisol est élevée et plus l'insulinémie l'est également ?
3. Peut-on penser que les boiteries sont plus présentes chez les individus hirsutes ?
4. Peut-on penser que PUPD peut-être un indicateur de l'hirsutisme ?
5. Tester si l'une des caractéristiques quantitatives est indicatrice de l'hirsutisme.
6. Existe-t-il un lien entre le statut PUPD et le statut polyghagie ?
7. Existe-t-il un lien entre l'hyperhidrose et le statut PUPD ? de même avec le diagnostique.

Partie 2 :On se restreint aux individus hirsutes de l'échantillon.

1. Peut-on penser que la proportion des chevaux et celle des poneys est la même chez les hirsutes ?
2. Peut-on penser que pour les hirsutes, le taux de glycémie moyen est supérieur à 1?
3. Peut-on penser que, chez les hirsutes, les chevaux ont un taux de glycémie supérieur aux poneys ?
4. Peut-on penser que chez hirsutes, plus l'on est âgé plus on a un taux de glycémie élevé ?
5. Chez les hirsutes, peut-on penser que les variations de poids sont plus importantes chez les chevaux que chez les poneys ?
6. Chez les hirsutes, peut-on penser qu'il existe un lien entre le cortisol et l'insulinémie ?